



Expresiones regulares

reg[ular]
expr[essio]n

Compiladores
Prof. Luis Enrique Hernández Olvera



Contenido

- Repaso de definiciones.
- Lenguajes Regulares
- Expresiones regulares
- Operadores de las expresiones regulares

Compiladores
Prof. Luis Enrique Hernández Olvera

2



Repasando definiciones

- Un conjunto no vacío y finito de símbolos se conoce como alfabeto (Σ).
- Una secuencia finita de símbolos de un determinado alfabeto se conoce como palabra sobre dicho alfabeto (a-z).
- Cada símbolo de un alfabeto es una cadena sobre dicho alfabeto.
- La cadena vacía, la cual se denota por el símbolo ϵ (λ), es una palabra sobre cualquier alfabeto.



Repasando definiciones

- Un **lenguaje** es un conjunto de palabras. Por lo tanto el conjunto $\{1,12,123,1234,12345\}$ es un lenguaje sobre el alfabeto compuesto por dígitos.
- Si Σ es un alfabeto, también es un lenguaje (El formado por todas las cadenas con un único símbolo).



Repasando definiciones

- Dado que un lenguaje es un conjunto de cadenas, se puede tener el lenguaje compuesto por ninguna cadena (El lenguaje vacío).
- El lenguaje vacío se denota de la misma forma que el conjunto vacío \emptyset .



Repasando definiciones

- \emptyset , el **lenguaje vacío**, es un lenguaje de cualquier alfabeto.
- $\{\epsilon\}$, el lenguaje que consta sólo de la **cadena vacía**, también es un lenguaje de cualquier alfabeto.
- $\emptyset \neq \{\epsilon\}$; el primero no contiene **ninguna cadena** y el segundo sólo tiene **una cadena**.



Repasando definiciones

- El conjunto de todas las cadenas de un alfabeto Σ , se conoce como **cerradura de Σ** o **lenguaje universal de Σ** y se denota por Σ^* .
- Por ejemplo, si se tiene el alfabeto $\Sigma=\{1\}$, entonces:

$$\Sigma^* = \{\epsilon, 1, 11, 111, 1111, 11111, \dots\}$$



Repasando definiciones

- El conjunto de todas las cadenas de un alfabeto Σ se designa mediante Σ^* .

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots$$

- El conjunto de cadenas no vacías del alfabeto Σ se designa como **cerradura positiva Σ^+** .
- Por lo tanto las dos equivalencias son:

$$\begin{aligned}\Sigma^+ &= \Sigma^1 \cup \Sigma^2 \cup \Sigma^3 \cup \dots \\ \Sigma^* &= \Sigma^+ \cup \{\epsilon\}.\end{aligned}$$

Recuerda
 $\Sigma^0 = \{\epsilon\}$



Lenguajes Regulares

- Los lenguajes regulares sobre un alfabeto pueden ser usados para especificar la construcción de analizadores léxicos (programas que analizan un texto y extraen los lexemas o unidades léxicas) que hay en el mismo.



Lenguajes Regulares

- Los lenguajes más sencillos que formalmente se consideran son los **lenguajes regulares**.
- Un lenguaje regular se puede generar a partir de lenguajes básicos, con la aplicación de las operaciones de **unión**, **concatenación** y cerradura de Kleene un número finito de veces.



Lenguajes Regulares

- Los lenguajes regulares se llaman así porque sus palabras contienen “**regularidades**” o repeticiones de los mismos componentes.
- Por ejemplo:
 - $L_1 = \{ab, abab, ababab, abababab, \dots\}$
 - En este ejemplo se aprecia que las palabras de L_1 son simplemente repeticiones de “ab” cualquier número de veces. Aquí la “regularidad” consiste en que las palabras contienen “ab” algún número determinado de veces.



Lenguajes Regulares

Un **lenguaje regular** es un tipo de **lenguaje formal** que satisface las siguientes propiedades:

- **Puede ser reconocido por:**
 - Un autómata finito determinista
 - Un autómata finito no determinista
 - Un autómata de pila
 - Un autómata finito alterno
 - Una máquina de Turing de solo lectura
- **Es generado por:**
 - Una gramática regular
 - Una gramática de prefijos
- **Es descrito por:**
 - Una expresión regular



Definición formal de lenguaje regular

- Sea Σ un alfabeto. El conjunto de los lenguajes regulares sobre Σ se define recursivamente como sigue:
 - El lenguaje vacío \emptyset es un lenguaje regular.
 - El lenguaje cadena vacía $\{\epsilon\}$ es un lenguaje regular.
 - Para todo $a \in \Sigma$, $\{a\}$ es un lenguaje regular.
 - Si A y B son lenguajes regulares, entonces $A \cup B$, $A \cdot B$ y A^* son lenguajes regulares.
 - Ningún otro lenguaje sobre Σ es regular.



Ejemplo

Dado $\Sigma = \{a, b\}$, las siguientes afirmaciones son ciertas:

- \emptyset y $\{\epsilon\}$ son lenguajes regulares
- $\{a\}$ y $\{b\}$ son lenguajes regulares
- $\{a, b\}$ es un lenguaje regular
- $\{ab\}$ es un lenguaje regular
- $\{a, ab, b\}$ es un lenguaje regular
- $\{a^i \mid i \geq 0\}$ es un lenguaje regular
- $\{a^i b^j \mid i \geq 0 \text{ y } j \geq 0\}$ es un lenguaje regular
- $\{(ab)^i \mid i \geq 0\}$ es un lenguaje regular



Expresiones regulares

- Una **expresión regular** es una forma abreviada de representar cadenas de caracteres que se ajustan a un determinado patrón. Al **conjunto de cadenas representado por la expresión r** se lo llama *lenguaje generado por la expresión regular r* y se escribe $L(r)$.
- Una expresión regular se define sobre un alfabeto Σ y es **una cadena formada por caracteres** de dicho alfabeto y por una serie de **operadores**.



Expresiones regulares

- Las expresiones regulares sirven como lenguaje de entrada de muchos sistemas que procesan cadenas por ejemplo generadores de analizadores léxicos, como Lex o Flex.
- Un generador de analizadores léxicos acepta descripciones de las formas de las unidades lógicas, que son principalmente expresiones regulares, y produce un AFD que reconoce qué unidad lógica aparece a continuación en la entrada.



Expresiones regulares

Si Σ es un alfabeto, una expresión regular sobre este alfabeto se define de la siguiente forma:

- \emptyset es una expresión regular que denota el lenguaje vacío.
- ϵ es una expresión regular que denota el lenguaje $\{\epsilon\}$
- Si $a \in \Sigma$, a es una expresión regular que denota el lenguaje $\{a\}$
- Si r y s son expresiones regulares, entonces $r \cup s$, $r \cdot s$ y r^* también lo son.



Operadores de las expresiones regulares

- Unión: $(r+s)$ es una expresión regular que denota el lenguaje $R \cup S$.
- Concatenación: (rs) es una expresión regular que denota el lenguaje $R \cdot S$
- Clausura: r^* es una expresión regular que denota el lenguaje R^* .



Ejemplos

$$\Sigma = \{0,1\}$$

- 00 El conjunto $\{00\}$
- 01^* Conjunto de palabras que empiezan por 0 y después tienen una sucesión de unos.
- $(1+10)^*$ Conjunto de palabras en las que los ceros están precedidos siempre por unos.
- $(0+1)^*011$ Conjunto de palabras que terminan en 011



Ejemplos

$$\Sigma = \{0,1\}$$

- 0^*1^* Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ambas sucesiones pueden ser vacías.
- 00^*11^* Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ninguna de las sucesiones puede ser vacía.

A r^*r se le denota como r^+ . Por lo que en la última expresión regular quedaría como 0^+1^+



Ejemplos

$$\Sigma = \{a, b\}$$

- $a|b$ denota el lenguaje $L(a|b) = \{a, b\}$.
- $(a|b)(a|b)$ denota a $L((a|b)(a|b))$, el lenguaje de todas las cadenas de longitud dos sobre el alfabeto Σ .
- $(a|b)(a|b) = aa|ab|ba|bb$
- $L(a^*) = \{\lambda, a, aa, aaa, \dots\}$, todas las cadenas de cero o más a's.



Ejemplos

$$(a)|((b)^*(c)) = a|b^*c$$

- Descripción:
 - Conjunto de cadenas que son una sola a o ninguna o más b's seguidas por una c.
- Algunas cadenas del lenguaje:
 - $L(a|b^*c) = \{a, c, bc, bbc, bbbbc, \dots\}$



Ejercicio

Dado $\Sigma = \{a,b,c\}$ y la E.R. $c^*(a|bc^*)^*$ ¿Describe el lenguaje de todas las cadenas sobre el Σ que no contiene ninguna subcadena ac es regular?



Ejercicio (Solución)

Dado $\Sigma = \{a,b,c\}$ y la E.R. $c^*(a|bc^*)^*$ ¿Describe el lenguaje de todas las cadenas sobre el Σ que no contiene ninguna subcadena ac es regular?

- $\{c\}, \{a\}, \{b\}$ son L.R. (3)
- $\{c\}^*$ es un L.R. (4, *)
- $\{b\}\{c\}^*$ es un L.R. (4, ·)
- $\{a\} \cup \{b\}\{c\}^*$ es un L.R. (4, U)
- $(\{a\} \cup \{b\}\{c\}^*)^*$ es un L.R. (4, *)
- $\{c\}^*(\{a\} \cup \{b\}\{c\}^*)^*$ es un L.R. (4, ·)



Equivalencias en Expresiones Regulares

- Existen muchas equivalencias con respecto a expresiones regulares basadas en las correspondientes igualdades de lenguajes. Se resumen en el siguiente teorema.
- Sean r, s y t expresiones regulares sobre el mismo alfabeto Σ . Entonces:



Equivalencias en Expresiones Regulares

1. $r \cup s = s \cup r$
2. $r \cup \emptyset = r = \emptyset \cup r$
3. $r \cup r = r$
4. $(r \cup s) \cup t = r \cup (s \cup t)$
5. $r\epsilon = \epsilon r = r$
6. $r\emptyset = \emptyset r = \emptyset$
7. $(rs)t = r(st)$
8. $r(s \cup t) = rs \cup rt$
9. $(r \cup s)t = rt \cup st$

10. $r^* = r^{**} = r^*r^* = (\epsilon \cup r)^* = r^*(r \cup \epsilon) = (r \cup \epsilon)r^* = \epsilon \cup rr^*$
11. $(r \cup s)^* = (r^* \cup s^*)^* = (r^*s^*)^* = (r^*s)^*r^* = r^*(sr^*)^*$
12. $r(sr)^* = (rs)^*r$
13. $(r^*s)^* = \epsilon \cup (r \cup s)^*s$
14. $(rs^*)^* = \epsilon \cup r(r \cup s)^*$
15. $s(r \cup \epsilon)^*(r \cup \epsilon) \cup s = sr^*$
16. $rr^* = r^*r$



Ejercicios

- Describa los lenguajes generados por las siguientes expresiones regulares y enumere al menos 7 cadenas de cada lenguaje. $\Sigma = \{a, b, c, d, e, \dots, z\}$
- $(ab)|(cz)|d^*$
- $a+b+c \mid (b+d)z$
- $(abc)^*z$
- $(a|b)^*|a$
- $(ab)^+ (bc)^+$